Навигация робота-пылесоса по командам на казахском языке

Промежуточный отчёт: результаты этапа A (предварительно, dev-квартиры, не тест)

Алибек Жайлеубай · 17 октября 2026

Коротко

- Робот-пылесос в симуляторе Habitat ищет предмет в незнакомой квартире по команде на казахском (kk), смешанном казахско-русском (kk_ru) или английском (en). Сравниваются казахская VLM Qolda-4B, мультиязычная Qwen3-VL-4B того же размера и машинный перевод NLLB → Qwen.
- Последний запуск: **19 вариантов системы на одних и тех же 57 эпизодах** в 8 квартирах, которые не использовались ни для настройки, ни для калибровки (1083 эпизода, ~60 часов счёта).
- **Значимо:** мультиязычная Qwen теряет на казахском (en 24 → kk 14 из 57, p = 0.013), и весь разрыв — непонимание команды; у Qolda ошибок понимания 0 во всех языках. Проверка перед остановкой помогает (Qwen en 24 против 14, p = 0.041). Исправление ошибки D-069: Qolda kk 3 → 15 (p = 0.002).
- **Пока не значимо:** Qolda kk 15 против Qwen kk 14 — наравне; разрыв en − kk у Qolda меньше (10.5 п. против 17.5 п.). Слабое место Qolda — визуальная проверка на казахском, а не понимание языка.

Содержание

- 1. О работе: тема и цель
- 2. Гипотезы и научная новизна
- 3. Архитектура робота: какие модели за что отвечают
- 4. Последний запуск: что тестировали, видео
- 5. Результаты, сильные и слабые стороны, выводы
- 6. Что делаем дальше
- Приложения: все 19 вариантов, попарные сравнения, разбивка по предметам, термины

1. О работе: тема и цель

Задача. Zero-shot ObjectNav: робот без обучения на этой задаче должен найти в незнакомой квартире объект заданной категории (кровать, стул, диван, унитаз, телевизор, растение) и остановиться рядом с ним. Команда даётся естественной фразой, например «Төсек қайда? Шаршап тұрмын» («Где кровать? Я устал»). Карты квартиры у робота нет — он строит её сам по камере.

Зачем. Почти все работы по навигации роботов к объектам — на английском. Казахский — малоресурсный язык, в быту его часто смешивают с русским, и в казахских домах есть предметы, которых нет в англоязычных наборах данных (қазан, сандық, текемет). Работа отвечает на вопрос: *где и почему* навигация по казахской команде теряет качество по сравнению с английской и помогает ли родная казахская VLM по сравнению с мультиязычной и с машинным переводом.

Робот. Колёсный робот-пылесос: диаметр 0.34 м, камера RGB-D на высоте 0.15 м. Для сравнения с мировыми результатами тот же конвейер работает на стандартном агенте Habitat (камера на 0.88 м).

Среда. Симулятор Habitat-Sim, 3D-сканы реальных квартир HM3D, стандартный набор эпизодов HM3D ObjectNav v1. Команды написаны носителями языка параллельно на kk, kk_ru и en.

2. Гипотезы и научная новизна

Гипотеза	Как проверяем	Что есть сейчас (dev)
H1. Потеря на казахском возникает на стыке «язык → зрение» (понимание команды, детекция, проверка), а не в навигации	Каждая неудача относится ровно к одному этапу; разрыв SR(en) − SR(kk) раскладывается на вклады этапов. H1 подтверждается, если вклад «язык + восприятие» больше половины разрыва	Qwen: весь разрыв 17.5 п. — непонимание языка (значимо, p = 0.013). Qolda: разрыв 10.5 п., целиком в визуальной проверке; навигация — 0. **Поддерживается**
H2. Для культурных предметов разрыв больше, а машинный перевод его увеличивает	Пары «культурный ↔ обычный» (қазан ↔ кастрюля, сандық ↔ сундук, текемет ↔ ковёр): фото и 3D-модели в сценах; сравнивается разрыв en − kk	Пилот (без робота): переводчик правильно передал культурный предмет в 1 из 15 команд, Qolda — в 11 из 15 (p = 0.002). На роботе ещё не проверялось
H3. Родная казахская модель сокращает казахский разрыв; на английском она не лучше	Qolda kk против Qwen kk на одних эпизодах; взаимодействие $(\text{Qolda} - \text{Qwen})_{kk} - (\text{Qolda} - \text{Qwen})_{en}$	Qolda kk 15 против Qwen kk 14 из 57 — наравне. Разрыв en − kk у Qolda меньше (10.5 против 17.5 п.), взаимодействие +7 п. в пользу H3. Пока не значимо
H4. Проверка VLM перед остановкой повышает успех, но требует калибровки уверенности	С проверкой против без проверки; ошибка калибровки (ECE) до и после	Qwen en: 24 против 14 без проверки (p = 0.041). ECE после калибровки: Qolda 0.071 → 0.033, Qwen 0.137 → 0.017. На казахском у Qolda проверка пока не помогает

Таблица 1. Гипотезы. Главная проверка — главная таблица на тестовых квартирах (547 эпизодов) после заморозки плана анализа; всё в этом отчёте — dev-данные.

Научная новизна

- **Новая постановка.** ObjectNav без обучения по командам на малоресурсном казахском и смешанной казахско-русской речи, на низком роботе-пылесосе. Насколько нам известно, такой работы нет (проверяется обзором литературы).
- **Где ломается язык.** Метод разложения потерь по этапам: разрыв «казахский против английского» точно делится на язык, восприятие и навигацию. Применим к любому языку и любой модульной системе.
- **Родная модель в замкнутом цикле.** Сравнение родной VLM, мультиязычной VLM и машинного перевода в цикле навигации, а не только на тестах вопросов и ответов. Уже видно: понимание команды и визуальная проверка — разные способности.
- **Культурные предметы.** Пары культурных и обычных предметов с одинаковой вставкой в сцены — новый ресурс для культурно-обусловленного воплощённого ИИ.
- **Открытые ресурсы.** Банк команд от носителей (kk / kk_ru / en, с рецензированием), казахский словарь категорий, стенд с роботом-пылесосом и пересчитанными под камеру 0.15 м критериями успеха.
- **Строгость.** План анализа фиксируется до теста; единица анализа — квартира; поправка Holm; все решения записаны в журнал до прогонов (D-001 … D-069).

3. Архитектура робота

Система модульная, в духе VLFM (Yokoyama et al., 2024): классическая навигация по своей карте плюс готовые нейросети для зрения и языка. Ни одна модель не обучается на нашей задаче. Языковая модель (VLM) вызывается редко — только чтобы понять команду и проверить находку; детектор работает на каждом шаге. Детектор, маски, карта и навигация одинаковы во всех вариантах, поэтому разница между вариантами — это разница в обработке языка.

3.1. Схема конвейера

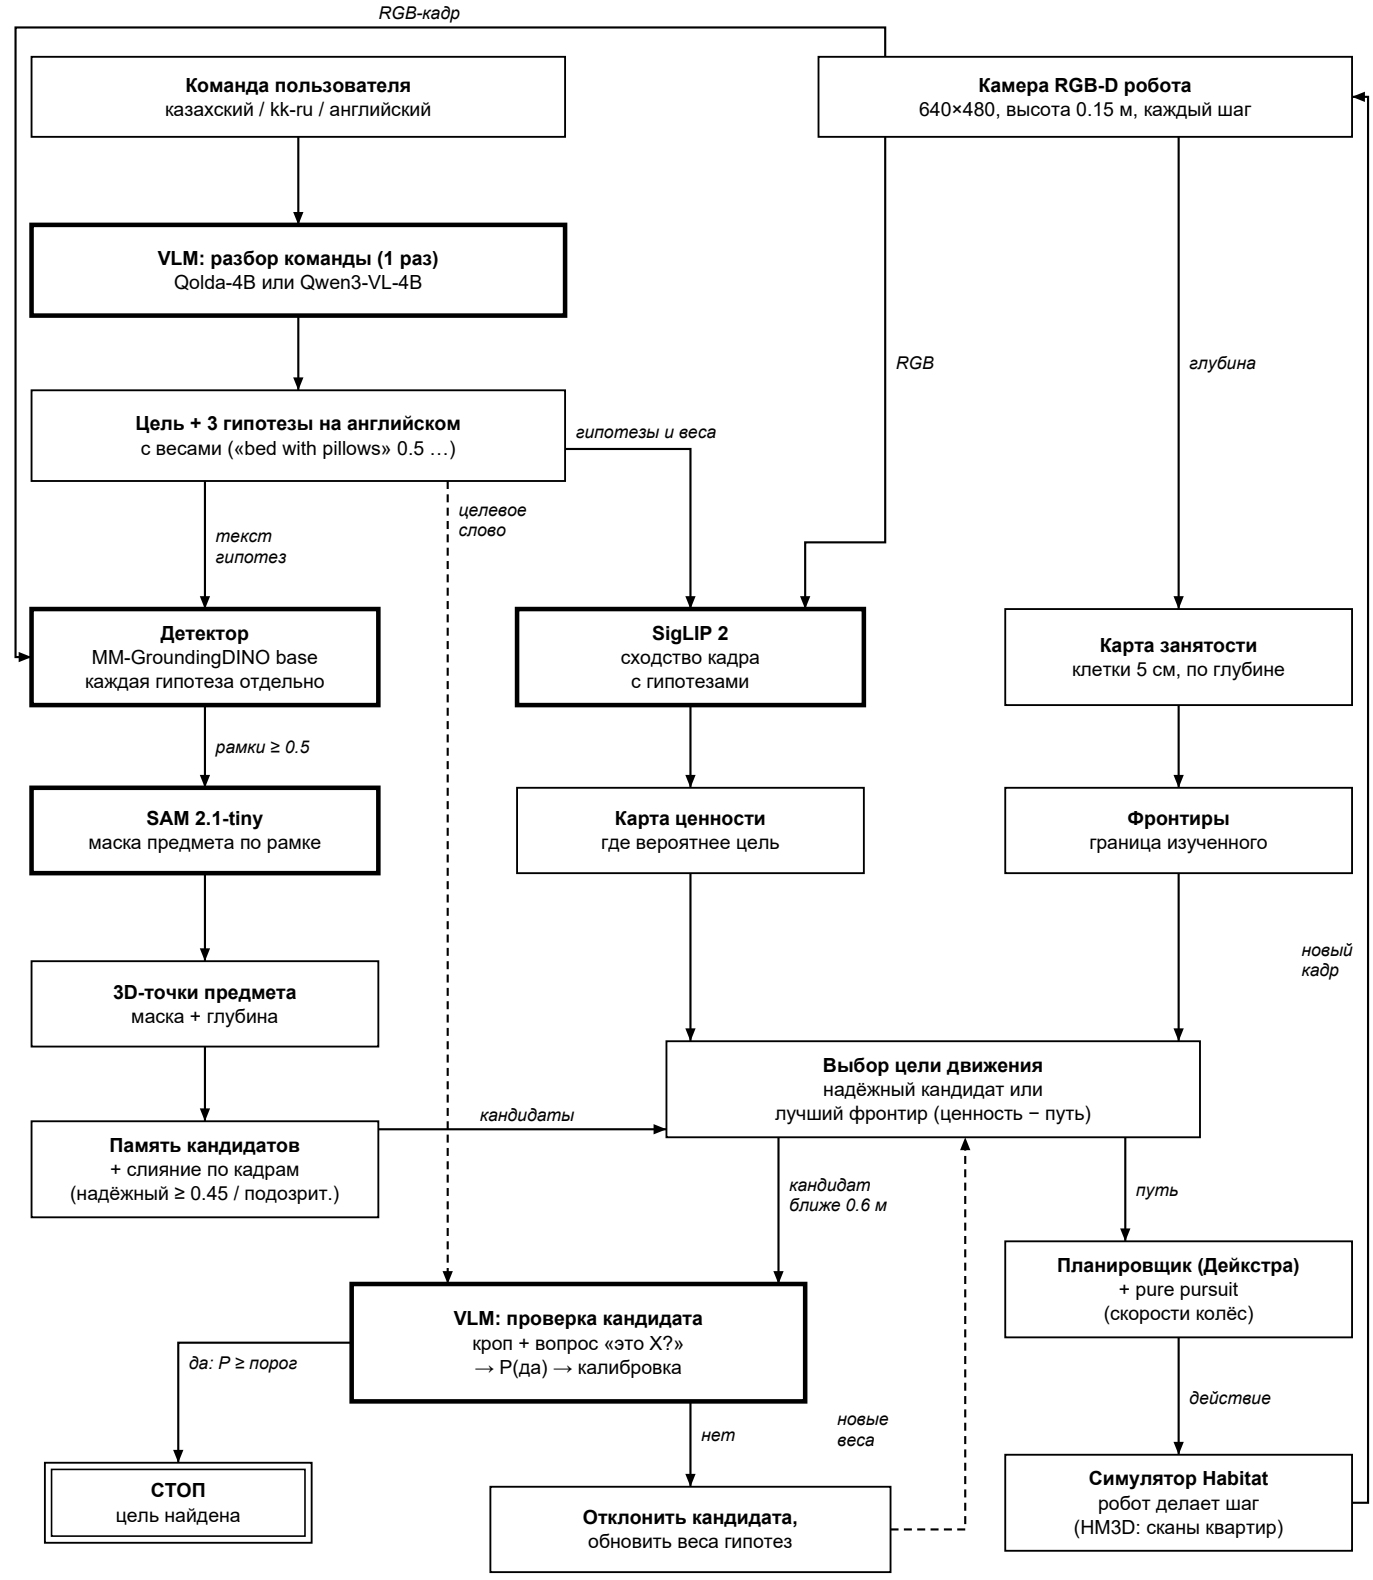


Рис. 1. Один шаг робота (0.5 с). Толстая рамка — нейросеть, тонкая — алгоритм, двойная — конец эпизода. Разбор команды выполняется один раз; проверка — только когда робот подъехал к кандидату ближе 0.6 м (~2–3 раза за эпизод). Остальное — на каждом шаге.

3.2. Модели: кто за что отвечает

Модель	Роль	Вход → выход	Сколько раз	Время	Где работает
Qolda-4B (казахская VLM от ISSAI; InternViT-300M + Qwen3-4B) *или* **Qwen3-VL-4B-Instruct**	понимание команды и визуальная проверка	разбор: текст команды → JSON с целью и 3 гипотезами; проверка: кроп + вопрос → вероятность «да»	разбор 1 раз на команду; проверка ~2–3 раза за эпизод	разбор ~6 с, проверка ~1 с	отдельный сервер на GPU, bf16, ~8 ГБ
MM-GroundingDINO base (Swin-B)	открытый детектор: ищет объект по тексту	кадр + одно английское описание → рамки с уверенностью	каждый шаг × число описаний (~1200–2000 проходов за эпизод)	~0.1 с / проход	процесс робота, GPU
SAM 2.1-tiny	сегментатор: точный контур объекта	кадр + рамка → маска	только в шагах с находками (~30%)	доли секунды	процесс робота, GPU
SigLIP 2 base	«похоже ли на цель», карта ценности	кадр + описания → сходство	каждый шаг (тексты кодируются 1 раз)	доли секунды	процесс робота, GPU
NLLB-200 600M	машинный перевод (только варианты «переводчик»)	казахская команда → английская	1 раз на команду	~1 с	процессор
Идеальный детектор (не модель)	эталон: распознавание по разметке симулятора	пиксели цели → точная маска	каждый шаг, только вариант «потолок»	—	—

Таблица 2. Нейросети в системе. Видеопамять: сервер VLM ~8 ГБ + процесс робота ~3.5 ГБ на карте 12 ГБ, поэтому одновременно работает одна VLM. Эпизод с VLM длится 3.5–6 минут, из них на VLM ~10 секунд.

3.3. Что происходит на каждом шаге

Карта занятости. 19 200 точек глубины (каждый 4-й пиксель) переводятся в 3D. Препятствие — точка на высоте 0.03–0.195 м: в это пылесос упрётся; выше он проезжает (под столом), ниже 5 см под уровнем пола — обрыв. Клетки вдоль луча отмечаются «свободно», клетка с препятствием — «занято». Свидетельства копятся в логарифме шансов: клетка становится занятой после двух наблюдений, так одна шумная точка не перекрывает проход.

Фронтиры и карта ценности. Фронтир — граница известной свободной области с неизвестной. SigLIP 2 сравнивает кадр с фразами «a photo of a bed with pillows.» и т. д.; взвешенная сумма записывается в видимые клетки с уверенностью, падающей к краю кадра. Робот едет к фронтиру с наибольшим «ценность − 0.002 × длина пути», то есть туда, где «пахнет кроватью», а не к ближайшему неизвестному (идея VLFM).

Поиск и кандидаты. Детектор проверяет каждое из трёх описаний отдельным проходом, рамки с уверенностью ≥ 0.5 проходят дальше. SAM 2 вырезает контур (иначе в рамку попадает стена позади), точки маски переводятся в 3D, точки у пола отбрасываются. Детекции ближе 0.6 м объединяются в одного кандидата. Уверенность кандидата сливается по кадрам: увидели снова — растёт; должен был быть виден, но детектор промолчал — падает. Кандидат с уверенностью ≥ 0.45 считается надёжным, и к нему робот едет.

Решение. Сначала осмотр на 360°. Затем: надёжный кандидат ближе 0.6 м и виден в кадре — проверка; кандидат дальше — подъезд; иначе — фронтир; фронтиров нет — к подозрительным кандидатам; ехать некуда — конец эпизода.

Путь и движение. Планировщик — алгоритм Дейкстры по 8-связной сетке своей карты: известное 1, неизвестное 1.5, штраф у стен; препятствия расширены на радиус робота. Контроллер pure pursuit ведёт робота к точке в 20 см впереди по пути (до 0.3 м/с). Упёрся — сдаёт назад и ставит на карту виртуальное препятствие. Робот не видит navmesh и разметку сцены: это знает только оценщик.

3.4. Языковой модуль

Разбор команды. Промпт на казахском просит ответить строго JSON: цель в словарной форме и 3–5 английских визуальных описаний с весами. Настоящий ответ Qolda на «Төсекті тауып берші»:

```
{"target": "төсек",
 "hypotheses": [{"en": "bed with white sheets", "w": 0.5},
                {"en": "bed in a bedroom",      "w": 0.3},
                {"en": "bed with pillows",      "w": 0.2}],
 "rooms": ["bedroom"]}
```

Ответ проверяется по схеме (только латиница в описаниях, веса 0..1); при ошибке модель получает её текст и исправляет, до 3 попыток. Температура 0: при одинаковом входе разбор одинаков. Для сравнения, Qwen на ту же команду ответила «door standing open», «door slightly ajar»: слово «төсек» она не знает.

Проверка перед остановкой. Вопрос задаётся на языке команды: «Суреттегі негізгі зат «төсек» болып табыла ма? Тек «иә» немесе «жоқ» деп жауап бер.» Нужна не только буква ответа, но и уверенность: сервер возвращает 10 самых вероятных первых токенов, и P(иә) считается по их вероятностям. Казахские слова токенизатор режет по буквам, поэтому варианты ответа начинаются с разных букв (и / ж).

Калибровка. Сырая уверенность моделей нечестная: Qwen говорит 0.98 про чужие предметы, Qolda — 0.3–0.5 про настоящие цели. Platt scaling переводит её в честную вероятность, порог подбирается по максимуму F1; оба — на 1100–1700 ответах из dev-квартир, где правда известна из симулятора:

$$P_{\text{честная}} = \text{sigmoid}(a \cdot \text{logit}(P_{\text{сырая}}) + b)$$

Модель	a	b	Порог	ECE до → после	AUROC
Qolda-4B	0.51	−0.58	0.30	0.071 → 0.033	~0.80
Qwen3-VL-4B	0.16	−1.41	0.41	0.137 → 0.017	0.84 (kk) / 0.93 (en)

Таблица 3. Параметры калибровки (D-067). AUROC — насколько хорошо модель отличает «цель / не цель» (0.5 — как монетка); ECE — ошибка калибровки.

Несколько взглядов на одного кандидата складываются в логарифме шансов; повторные взгляды засчитываются с коэффициентом 0.5, потому что они коррелированы. **Исправление D-069:** раньше коэффициент 0.5 применялся и к первому взгляду, поэтому первый ответ должен был быть заметно выше порога; теперь первый ответ засчитывается полностью.

Веса гипотез. Ответ проверки уточняет, какое из описаний «правильное». Если кандидат, найденный по «bed in a bedroom», оказался кроватью, вес этого описания растёт (байесовское обновление), и карта ценности дальше опирается на него.

3.5. Как оценивается результат

Успех — робот сказал «стоп» не дальше 0.1 м от точки обзора цели (место в пределах 1 м, откуда цель видна с камеры робота; точки пересчитаны под высоту 0.15 м). Это стандарт habitat-lab. **SPL** — успех с поправкой на длину пути. Каждая неудача относится к одному этапу: не понял команду; цель не попала в кадр; детектор не узнал; проверка отвергла настоящую цель; остановился у чужого предмета; видел, но не доехал; застрял.

Идеальный робот — тот же робот, но распознавание берётся из разметки симулятора. Это потолок навигации: он показывает, сколько теряется на распознавании, а сколько на самой езде.

Воспроизводимость: эпизод зависит только от его номера; каждый вызов модели, картинка и решение записаны; повтор эпизода даёт тот же результат (проверено на 41 повторе).

4. Последний запуск: этап A, 19 вариантов на одних и тех же эпизодах

Зачем. Предварительный просмотр главной таблицы на квартирах, которые не участвовали ни в настройке, ни в калибровке, с видео одних и тех же эпизодов во всех вариантах. Ничего по этим результатам не подбиралось.

Условия. 57 эпизодов в 8 квартирах HM3D (train), по 8–10 на категорию; робот-пылесос; лимит 800 шагов; проверка откалибрована и исправлена (D-069), где не сказано иное. Всего 1083 эпизода, ~60 часов чистого счёта на одной RTX 5070.

Группа вариантов	Что меняется	Зачем
Qolda kk / kk_ru / en, с проверкой	родная казахская VLM разбирает команду и проверяет находку	главный метод; сравнение языков (H1)
Qwen kk / kk_ru / en, с проверкой	то же с мультиязычной VLM того же размера	родная модель против мультиязычной (H3)
Переводчик NLLB → Qwen kk / kk_ru	команду переводят на английский, дальше всё делает Qwen по-английски	«а может, просто перевести?»
Без проверки: Qolda и Qwen × kk / kk_ru / en	робот останавливается у первого надёжного кандидата	нужна ли проверка (H4); понимание языка отдельно от проверки
Qolda до исправления kk / kk_ru / en	проверка с найденной ошибкой D-069	эффект исправления
Английский робот без VLM	детектору дают слово категории «bed», команду не разбирают	базовая линия как VLFM
Идеальный робот	распознавание по разметке симулятора	потолок навигации

Таблица 4. Варианты системы в этапе A (всего 19).

Видео

Для показа собраны 8 роликов. На каждой плитке подпись: вариант и исход. Сверху в плитке — команда, гипотезы модели, решение робота; справа — карта робота и карта ценности. Шесть роликов «рядом» — все эпизоды, у которых видео пишется во всех вариантах (выбраны заранее по номеру эпизода, не по результату). Два ролика с кроватью подобраны как иллюстрация непонимания слова «төсек» мультиязычной моделью. Ниже — кадры из двух роликов; сами ролики — в папке `reports/demo_2026-10-17/video/`.

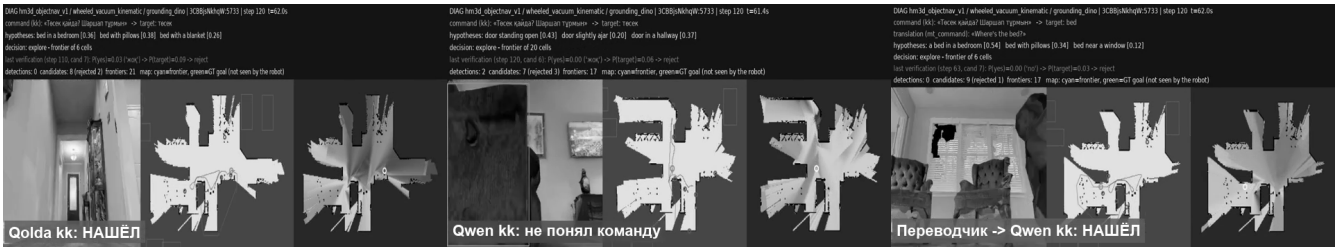


Рис. 2. «Төсек қайда? Шаршап тұрмын» («Где кровать? Я устал»), шаг 120. Слева Qolda kk — гипотезы «bed in a bedroom», «bed with pillows»; в центре Qwen kk — гипотезы «door standing open», «door slightly ajar» (ищет дверь); справа переводчик → Qwen. Итог: Qolda и переводчик нашли кровать, Qwen kk — нет.



Рис. 3. Диван, шаг ~100. Сверху: Qolda kk, Qwen kk, переводчик → Qwen; снизу: Qolda kk_ru, Qwen kk_ru, английский робот без VLM. Оба варианта kk_ru подъехали, но проверка отвергла настоящий диван.

Файл	Команда / предмет	Что видно
krovat_3CBBjsNkhqW_5733.mp4	«Төсек қайда? Шаршап тұрмын»	Qolda kk нашла; Qwen kk не поняла команду и искала дверь; переводчик → Qwen нашёл. Английский робот без VLM в этом эпизоде кровать не нашёл
krovat_CthA7sQNTPK_14783.mp4	«Төсекті тауып берші»	Qolda kk нашла кровать за 162 шага; Qwen kk не поняла команду (800 шагов поиска двери); переводчик → Qwen нашёл за 734 шага
ryadom_toilet_wPLokgvCnuk_39344.mp4	унитаз	все шесть вариантов находят цель: простой случай, где язык не мешает
ryadom_sofa_YmWinf3mhb5_22236.mp4	диван	Qolda kk, Qwen kk, переводчик и английский робот находят; оба варианта kk_ru — проверка отвергла настоящий диван
ryadom_sofa_YmWinf3mhb5_23069.mp4	диван	Qolda kk — проверка отвергла цель; Qwen kk остановилась далеко; переводчик, kk_ru и английский робот находят
ryadom_plant_wPLokgvCnuk_16636.mp4	растение	находят переводчик и Qwen kk_ru; Qolda kk и английский робот останавливаются у чужого предмета
ryadom_chair_CthA7sQNTPK_38153.mp4	стул	трудный эпизод: не находит ни один реальный вариант (только идеальный робот); переводчик неправильно перевёл команду
ryadom_chair_qk9eeNeR4vw_6635.mp4	стул	тоже не находит никто: ложные остановки, «видел, но не доехал», ошибка перевода

Таблица 5. Видео (reports/demo_2026-10-17/video/; уменьшенные копии — video/web/). Ролики «ryadom»: Qolda kk, Qwen kk, переводчик → Qwen kk, Qolda kk_ru, Qwen kk_ru, английский робот без VLM; ролики «krovat»: Qolda kk, Qwen kk, переводчик → Qwen kk.

5. Результаты

Вариант (57 эпизодов)	kk	kk_ru	en
Qolda, с проверкой	26.3% (15)	29.8% (17)	36.8% (21)
Qwen, с проверкой	24.6% (14)	33.3% (19)	42.1% (24)
Переводчик NLLB → Qwen	35.1% (20)	31.6% (18)	—
Qolda без проверки	31.6% (18)	35.1% (20)	33.3% (19)
Qwen без проверки	28.1% (16)	24.6% (14)	24.6% (14)
Qolda до исправления D-069	5.3% (3)	17.5% (10)	22.8% (13)
Английский робот без VLM			40.4% (23)
Идеальный робот (потолок)			78.9% (45)

Таблица 6. Успех (доля эпизодов, где робот остановился у цели), в скобках — число успехов из 57. 95% доверительный интервал на 57 эпизодах — около ±12 п., поэтому разницы меньше ~10 п. пока не доказаны. Значимость — точный тест McNemar на одних и тех же эпизодах.

Откуда разрыв «английский − казахский» (H1)

Модель	en	kk	Разрыв	из-за языка	из-за восприятия	из-за навигации
Qolda	36.8%	26.3%	10.5 п.	0	10.5	0
Qwen	42.1%	24.6%	17.5 п.	17.5	3.5	−3.5

Таблица 7. Вклад этапа = доля эпизодов, проваленных на этом этапе в kk, минус то же в en; сумма вкладов равна разрыву. Язык — «не понял команду»; восприятие — «детектор не узнал», «проверка отвергла цель», «остановился у чужого предмета»; навигация — остальное.

Главные находки

Статистически значимые (p < 0.05):

- **Qwen теряет на казахском.** Qwen en 24 → kk 14 из 57 (p = 0.013). Весь разрыв — непонимание команды: в 10 эпизодах «төсек» понят как дверь. У Qolda ошибок понимания 0 во всех языках.
- **Проверка помогает.** Qwen en с проверкой 24 против 14 без неё (p = 0.041): проверка отсекает ложные остановки.
- **Исправление D-069.** Найденная по логам ошибка в правиле остановки; после исправления Qolda kk 3 → 15 (p = 0.002).

Направление (пока не значимо):

- **Qolda против Qwen на kk: 15 против 14** — наравне, но теряют по-разному: Qwen — в понимании языка, Qolda — в визуальной проверке на казахском. Без проверки на kk_ru Qolda 20 против 14 (+10.5 п., p = 0.21).
- **Разрыв у Qolda меньше:** Qolda теряет на казахском 10.5 п., Qwen — 17.5 п. Преимущество Qwen на английском (+3 эпизода) на казахском исчезает (Qolda +1) — это направление гипотезы H3.

- **Переводчик → Qwen на kk: 35.1% (20)** — лучший казахский вариант с проверкой, хотя переводчик неправильно понял 14 команд (стулья, унитазы): выигрывает за счёт сильной английской проверки Qwen. На kk_ru переводчик уже не впереди (18).
- Потолок навигации (идеальное распознавание) — 79%; английский робот без VLM — 40%; лучший VLM-вариант (Qwen en) — 42%. Телевизоры не находит почти никто: камера у пола не видит экран на стене вблизи.

Сильные и слабые стороны

Сильные стороны	Слабые стороны
• Навигация работает: с идеальным распознаванием 79%, цель попадает в кадр в ~90% эпизодов. • Qolda понимает казахские и смешанные команды без ошибок; мультиязычная модель и переводчик ошибаются в 10–14 эпизодах из 57. • Лучший английский VLM-вариант (Qwen en, 42%) на уровне базовой линии; на стандартном агенте проверка ранее дала 43% против 30% (dev). • Диагностика по логам находит конкретные причины потерь (так найдена ошибка D-069). • Строгая методика: одинаковые эпизоды для всех вариантов, правила до прогонов, воспроизводимость.	• Визуальная проверка Qolda на казахском неуверенна: отвергает настоящую цель в 8 эпизодах против 2 на английском. • Калибровка подобрана на 10 квартирах и хуже переносится на новые. • Много ложных остановок у вариантов без проверки и много «видел, но не доехал» у вариантов с проверкой. • Телевизоры почти не находит никто: камера у пола не видит экран на стене вблизи. • 57 эпизодов — мало для доказательства разниц меньше 10 п.; это dev, не тест. • Одна видеокарта: ~60 часов счёта на один такой запуск.

К чему пришли

Казахская команда сама по себе роботу не мешает: родная модель понимает её без ошибок, а мультиязычная значимо теряет на непонимании. Абсолютный успех казахского робота пока ограничен не языком, а последним модулем — визуальной проверкой, которая на казахском у Qolda неуверенна. Именно поэтому в сумме Qolda kk и Qwen kk наравне, а переводчик с сильной английской проверкой Qwen выходит вперёд. Если сделать проверку одинаковой для всех языков, останется только разница в понимании казахского, где Qolda сильнее.

6. Что делаем дальше

Шаг	Зачем	Оценка
Проверка, независимая от языка: вопрос по-английски по английской гипотезе, одинаково для всех вариантов	убрать штраф казахской проверки; сравнение моделей сведётся к пониманию языка	dev, ~1–2 дня
Калибровка на большем числе квартир и проверка переноса	порог, который работает на новых квартирах	~1 день
«Не бросать цель по дороге»; правило остановки для высоких предметов (телевизоры)	самые большие потери после проверки	dev, ~2–3 дня
Стандартный агент с Qolda kk / kk_ru	сравнение с мировыми результатами (VLFM 52.5% на HM3D)	~1–2 дня
Культурные предметы: фото и 3D-модели (қазан, сандық, текемет…)	главная проверка H2: где перевод ломается	сбор данных
60 тестовых команд от носителей, заморозка плана анализа	условие для теста	сбор данных
Главная таблица на тестовых квартирах (547 + 297 эпизодов), таблица (а), устойчивость	подтверждение гипотез	~3 недели на своей видеокарте или ~2–4 дня на арендованной (~$100–200)
Обсудить: дообучение «зрения» Qolda на кропах из тренировочных квартир	сильнее проверка на казахском; меняет постановку (уже не zero-shot)	~1.5–3 недели

Таблица 8. План. Всё до заморозки плана анализа — только на dev-квартирах; тестовые квартиры не используются.

Приложение А. Все 19 вариантов

Вариант	Успех	%	95% ДИ	SPL	не понял	не узнал	отверг	чужой	не в кадре	не доехал	застрял	далеко
Английский робот без VLM (как VLFM)	23	40.4	29–53	0.180	0	2	0	21	0	6	2	3
Идеальный робот (потолок навигации)	45	78.9	67–88	0.443	0	0	0	0	2	9	1	0
Qolda kk	15	26.3	17–39	0.084	0	1	8	8	2	19	2	2
Qolda kk_ru	17	29.8	20–43	0.103	0	1	9	4	2	21	1	2
Qolda en	21	36.8	26–50	0.150	0	2	2	7	2	17	2	4
Qwen kk	14	24.6	15–37	0.090	10	1	5	1	2	20	2	2
Qwen kk_ru	19	33.3	22–46	0.133	0	2	6	3	2	24	1	0
Qwen en	24	42.1	30–55	0.157	0	1	4	0	2	22	2	2
Переводчик NLLB → Qwen (kk)	20	35.1	24–48	0.099	14	0	5	0	2	14	1	1
Переводчик NLLB → Qwen (kk_ru)	18	31.6	21–44	0.108	4	3	12	1	2	15	1	1
Qolda kk без проверки	18	31.6	21–44	0.157	0	0	0	26	0	10	1	2
Qolda kk_ru без проверки	20	35.1	24–48	0.159	0	1	0	29	0	4	1	2
Qolda en без проверки	19	33.3	22–46	0.172	0	0	0	29	0	4	2	3
Qwen kk без проверки	16	28.1	18–41	0.128	8	1	0	25	2	3	2	0
Qwen kk_ru без проверки	14	24.6	15–37	0.131	0	1	0	32	2	7	1	0
Qwen en без проверки	14	24.6	15–37	0.122	0	0	0	31	1	7	1	3
Qolda kk — ДО исправления D-069	3	5.3	2–14	0.022	0	1	19	2	3	25	2	2
Qolda kk_ru — ДО исправления D-069	10	17.5	10–29	0.049	0	1	15	0	2	26	1	2
Qolda en — ДО исправления D-069	13	22.8	14–35	0.079	0	2	6	4	2	25	2	3

*Таблица А1. 57 эпизодов в каждой строке. Справа — на каком этапе провалились неудачные эпизоды (сумма = 57 − успехи): **не понял** — не понял команду; **не узнал** — цель была в кадре, детектор не узнал; **отверг** — проверка отвергла настоящую цель; **чужой** — остановился у чужого предмета; **не в кадре** — цель ни разу не попала в кадр; **не доехал** — видел цель, но не доехал; **застрял**; **далеко** — остановился у цели, но слишком далеко. Группы: язык — «не понял»; восприятие — «не узнал», «отверг», «чужой»; навигация — остальное. SPL — успех с поправкой на длину пути.*

Приложение Б. Попарные сравнения на одних и тех же эпизодах

Вопрос	A	B	A	B	A − B, п.	только A	только B	p
H3: казахская модель против мультиязычной на kk	Qolda kk	Qwen kk	15	14	+1.8	6	5	1.000
H3: то же на смешанной kk_ru	Qolda kk_ru	Qwen kk_ru	17	19	−3.5	4	6	0.754
H3 без проверки (только понимание команды)	Qolda kk без проверки	Qwen kk без проверки	18	16	+3.5	10	8	0.815
H3 без проверки, kk_ru	Qolda kk_ru без проверки	Qwen kk_ru без проверки	20	14	+10.5	11	5	0.210
контроль: на английском Qolda не обязана выигрывать	Qolda en	Qwen en	21	24	−5.3	6	9	0.607
H1: сколько Qolda теряет на казахском	Qolda en	Qolda kk	21	15	+10.5	12	6	0.238
H1: сколько Qwen теряет на казахском	Qwen en	Qwen kk	24	14	+17.5	12	2	**0.013**
родная модель против «перевести и отдать Qwen»	Qolda kk	Переводчик NLLB → Qwen (kk)	15	20	−8.8	6	11	0.332
то же на kk_ru	Qolda kk_ru	Переводчик NLLB → Qwen (kk_ru)	17	18	−1.8	7	8	1.000
H4: с проверкой против без (Qolda kk)	Qolda kk	Qolda kk без проверки	15	18	−5.3	8	11	0.648
H4: с проверкой против без (Qwen kk)	Qwen kk	Qwen kk без проверки	14	16	−3.5	4	6	0.754
H4: с проверкой против без (Qwen en)	Qwen en	Qwen en без проверки	24	14	+17.5	15	5	**0.041**
исправление D-069: после против до (Qolda kk)	Qolda kk	Qolda kk — ДО исправления D-069	15	3	+21.1	13	1	**0.002**
казахский робот на Qolda против английского робота без VLM	Qolda kk	Английский робот без VLM (как VLFM)	15	23	−14.0	5	13	0.096
лучший английский VLM-вариант против робота без VLM	Qwen en	Английский робот без VLM (как VLFM)	24	23	+1.8	8	7	1.000

Таблица Б1. «A», «B» в 4–5 столбцах — число успехов из 57; «только A» — эпизоды, где нашёл только A. p — точный тест McNemar; жирным — p < 0.05. Поправка на множественные сравнения не применялась (это предварительный просмотр).

Приложение В. Успехи по предметам

Вариант	кровать (из 10)	стул (из 10)	растение (из 8)	диван (из 10)	унитаз (из 10)	телевизор (из 9)
Английский робот без VLM (как VLFM)	5	2	1	9	5	1
Идеальный робот (потолок навигации)	9	8	7	10	10	1
Qolda kk	4	4	0	3	4	0
Qolda kk_ru	3	3	0	5	6	0
Qolda en	4	2	4	6	5	0
Qwen kk	0	3	0	6	5	0
Qwen kk_ru	5	3	1	6	4	0
Qwen en	5	3	0	9	7	0
Переводчик NLLB → Qwen (kk)	4	0	1	9	6	0
Переводчик NLLB → Qwen (kk_ru)	5	2	1	2	8	0
Qolda kk без проверки	3	2	2	6	4	1
Qolda kk_ru без проверки	4	2	2	5	5	2
Qolda en без проверки	3	3	3	4	2	4
Qwen kk без проверки	2	2	2	4	6	0
Qwen kk_ru без проверки	4	2	1	2	4	1
Qwen en без проверки	1	1	1	4	6	1
Qolda kk — ДО исправления D-069	1	1	0	1	0	0
Qolda kk_ru — ДО исправления D-069	4	1	0	4	1	0
Qolda en — ДО исправления D-069	3	2	2	3	3	0

Таблица В1. Число успехов по категориям цели (в заголовке — сколько эпизодов с этой категорией).

Термины

Термин	Что значит
VLM	Визуально-языковая модель: понимает и текст, и картинку (Qolda-4B, Qwen3-VL-4B).
Zero-shot	Модели не обучаются на нашей задаче: используются готовые, как есть.
Гипотеза (в роботе)	Английское визуальное описание цели от VLM («bed with pillows»), по нему ищет детектор.
Кандидат	Место на карте, где детектор видел возможную цель; у него есть уверенность.
Фронтир	Граница между изученной свободной областью и неизвестной — туда робот едет исследовать.
Проверка (verify)	Перед остановкой VLM смотрит на кроп кандидата и отвечает «это цель?» с вероятностью.
Калибровка	Пересчёт сырой уверенности модели в честную вероятность (Platt scaling) и выбор порога.
SR, SPL	SR — доля успешных эпизодов; SPL — успех с поправкой на длину пути (1 — кратчайший путь).
Идеальный робот	Тот же робот, но распознавание из разметки симулятора — потолок навигации.
dev / test	dev — тренировочные квартиры для настройки; test — отдельные квартиры только для итоговых цифр.
AUROC, ECE	AUROC — насколько хорошо модель отличает «есть / нет» (0.5 — как монетка); ECE — ошибка калибровки.
p, McNemar	p — вероятность получить такую разницу случайно; $p < 0.05$ — значимо. McNemar сравнивает два варианта на одних и тех же эпизодах.
D-0xx	Номер записи в журнале решений docs/decisions.md.