kznav: отчёт о работе за неделю 17–24 октября 2026

Робот ищет предмет по команде на казахском (Habitat-Sim, HM3D). Этапы 0–5 плана D-070, своя лёгкая проверка, итоговая система на стандартном роботе

Все числа — dev (сцены train HM3D); тест не трогали. Источник — docs/decisions.md, записи D-069 … D-076; правило «что считать успехом изменения» записывалось до каждого прогона.

1. Коротко

- **На стандартном роботе (камера на высоте 0.88 м, как в статьях) итоговая система с командами на казахском даёт 44.0% успеха** и значимо обходит обе базовые линии: без языковой модели 30.0% (p = 0.006) и закрытый детектор, как в VLFM, 30.7% (p = 0.008). Qolda на казахском — не хуже Qwen на английском (44.0 против 40.7%).
- **Ложных остановок у Qolda 15 из 150, у базовой линии 72.** На высокой камере проверка объекта работает.
- **На роботе-пылесосе (камера 0.15 м) успех на новых сценах поднять не удалось.** Пять изменений проверены по заранее записанным правилам; на свежих сценах ни одно не дало значимого прироста. Робот стал в 2–3 раза быстрее (меньше шагов, выше SPL).
- **Причина найдена и измерена:** у низкой камеры много похожих чужих предметов; проверка 4B-модели ошибается примерно в каждом втором–третьем решении «стоп», и робот останавливается у чужого предмета раньше, чем увидит нужный («лотерея ложных кандидатов»).
- **Выводы о языке устойчивы на всех наборах сцен:** Qolda понимает казахские команды без ошибок; Qwen и переводчик NLLB теряют эпизоды именно на понимании; Qolda значимо лучше переводчика (dev4, p = 0.022); проверка объекта значимо нужна (H4, p = 0.007).

2. Что изменили в системе за неделю

Конвейер прежний: модель один раз разбирает команду (цель, её английское имя, 3–5 английских описаний, комнаты) → детектор MM-GroundingDINO ищет эти описания в кадре → SAM 2 вырезает маску, кандидаты копятся на карте → карта ценности SigLIP 2 выбирает, куда ехать → у кандидата модель проверяет кроп («это он?») → робот останавливается. Изменения этой недели касаются в основном последних двух шагов.

изменение	что делает (просто)	статус	эффект
D-069: первый ответ проверки — полностью	Раньше первый ответ «да» засчитывался наполовину, и робот почти никогда не останавливался. Теперь один уверенный ответ — это ровно та величина, на которой подобран порог.	принято, по умолчанию	Qolda kk 5.3 → 26.3% (этап A, p = 0.002)
Калибровка проверки на 18 сценах	Перевод ответа модели в вероятность (Platt) и порог остановки (max-F1) подбираются по вызовам из 18 сцен вместо 10.	принято	надёжнее порог; выяснилось, что у Qolda на новых сценах падает сама различающая способность (AUROC 0.80 → 0.71)
«Последний метр»	Три механизма вместе: (1) закрепить цель, к которой робот поехал, пока не ответит проверка; (2) спрашивать уже с 1.5 м, когда предмет целиком в кадре; (3) останавливаться до 0.9 м там, где камера реально видит предмет (нужно для высоких предметов, например телевизора).	принято (со второй попытки)	шагов в 2–3 раза меньше, SPL +48–63%; настоящую цель отвергает втрое реже
Проверка по-английски с коротким именем	Вопрос к модели: «Is the main object in the image a "chair"?» Имя (target_en) пишет сама модель при разборе команды (промпт v4); пайплайн категорию не подсказывает.	принято (решение руководителя)	44.7% на настроечных сценах (лучший результат); проверка ни разу не отвергла настоящую цель
Остановка по видимости для идеального робота	Идеальный детектор (потолок навигации) встаёт там, где видит предмет.	принято	потолок 86.6 → 88.7%, телевизоры 6 → 9 из 17
Своя лёгкая проверка (SigLIP 2)	Вместо языковой модели кроп проверяет маленькая модель «картинка — текст»: быстро, без сервера модели.	встроена как опция; не принята	офлайн различает лучше Qolda (AUROC 0.88–0.94 против 0.71–0.80), на роботе +2 эпизода из 72
Вопрос по первой гипотезе	В вопрос подставлялось описание («black chair»).	не принято	хуже: стул не того цвета → «нет»
Закрепление цели без вопроса издалека	Механизм (1) отдельно.	не принято	21.2 против 37.6% (p = 0.009)

изменение	что делает (просто)	статус	эффект
Строгий порог остановки	Порог по точности ≥ 0.7 вместо max-F1.	не принято	ложных остановок меньше, но не успевает доехать: 38.8 против 44.7%
Поиск	Имя цели в запросах детектора, комната в карте ценности, перепроверка сохранённых кропов.	не принято	36.5 против 44.7%
Обученная проверка	Сеть поверх SigLIP, обученная на 16 тыс. кадров с камеры пылесоса.	не принято	на кропах робота хуже необученной (0.834 против 0.881)

Таблица 1. Изменения недели. «Принято» — прошло правило, записанное до прогона.

3. Как устроены эксперименты

- **Задача (ObjectNav).** Робот в незнакомой квартире получает команду («Төсек қайда? Шаршап тұрмын») и должен сам найти предмет и сказать «стоп». **Успех (SR)** — робот сам остановился не дальше 0.1 м от точки, откуда предмет виден (около 1 м от предмета). **SPL** — успех с учётом длины пути (1 — кратчайший путь).
- **Два робота.** Пылесос: камера на высоте 0.15 м, наклон 20° вверх, до 800 шагов. Стандартный агент Habitat: камера на 0.88 м, до 500 шагов, как в статьях (VLFM и др.).
- **Шесть предметов:** кровать, стул, растение, диван, унитаз, телевизор. Команды — естественные фразы, написанные носителями (12 dev-команд), на kk, kk_ru и en.
- **Только dev:** сцены train HM3D. Настройка — на 10 сценах (85 эпизодов, «настроечные»); проверка — на свежих сценах, нигде раньше не использованных: **dev3** (72 эпизода, 10 сцен) и **dev4** (72 эпизода, 10 сцен). Тест (val) не трогаем до заморозки плана анализа.
- **Правило до прогона:** для каждого изменения заранее записано, сколько успехов оно должно добавить, чтобы его приняли (обычно +3 из 85); одна, максимум две попытки.
- **Сравнения попарные:** все варианты едут одни и те же эпизоды; точный тест McNemar считает только эпизоды, где один вариант справился, а другой нет. На 72 эпизодах 95% интервал успеха ±11 п., на 150 — ±8 п.
- **Варианты (плечи):** Qolda / Qwen3-VL-4B с командой на одном языке; переводчик NLLB → Qwen; без языковой модели (как VLFM: готовое английское слово категории); закрытый детектор как в VLFM; идеальный детектор (знает, где предмет: потолок навигации).

4. Все эксперименты недели

№	этап, дата	что проверяли	где	результат (успех)	решение
1	0, 17.10	D-069 по умолчанию, калибровка 18 сцен, новые сцены dev3	—	перенос калибровки: Qolda AUROC 0.80 → 0.71 на новых сценах	принято
2	1а, 17.10	остановка по видимости	пылесос, 142 эп.	идеальный 86.6 → 88.7%; без VLM 38.0 → 26.8% (p = 0.005)	идеальному — да, базовой линии — нет
3	1б, 18.10	«последний метр»: a0 / a1 / a2	пылесос, 85 эп.	37.6 / 21.2 / 40.0%	не принято с 1-й попытки (+2 при правиле +3)
4	2, 18.10	английский вопрос по первой гипотезе: b0 / b2	пылесос, 85 эп.	31.8 / 36.5%	хуже; «последний метр» принят (b2 − b0 = +4)
5	2, 19.10	английский вопрос с коротким именем (промпт v4): c2	пылесос, 85 эп.	**44.7%**	принято — основной вариант
6	2′, 19.10	строгий порог остановки: c2s	пылесос, 85 эп.	38.8%	не принято
7	3, 19.10	поиск: имя в запросах, комната, перепроверка кропов	пылесос, 85 эп.	36.5%	не принято
8	4, 19–21.10	все 16 вариантов на свежих сценах	пылесос, dev3, 72 эп.	Qolda kk 23.6% (старые настройки 25.0%)	подтверждение: прироста нет
9	5′.0, 21.10	SigLIP «из коробки» на сохранённых кропах	9 586 кропов	AUROC 0.88–0.94 против 0.71–0.80 у Qolda	идём дальше
10	5′.1–2, 21.10	обученная проверка	16 065 кадров обучения	0.834 против 0.881 у необученной	не принято
11	5′.3а, 22.10	SigLIP-проверка на роботе	пылесос, dev3, 72 эп.	Qolda kk 26.4 против 23.6%	не принято (нужно ≥ +5)
12	5′.3б, 22.10	SigLIP-проверка на ещё одних свежих сценах	пылесос, dev4, 72 эп.	Qolda kk 20.8, Qwen kk 26.4, переводчик 8.3%	описательно
13	5, 22–23.10	**итоговая система на стандартном роботе**	агент, 150 эп.	**Qolda kk 44.0%, Qwen en 40.7%, без VLM 30.0%**	описательно; значимо выше базовой

Таблица 2. Все прогоны недели по порядку. a0 / b / c — названия вариантов в docs/decisions.md.

5. Результаты по этапам

5.1. «Последний метр» и английский вопрос (пылесос, 85 эпизодов настроечных сцен, Qolda kk)

вариант	вопрос проверки	последний метр	успех	SPL	шагов (медиана)	ложные ост.	проверка отвергла цель
a0 — как было	по-казахски	—	37.6%	0.119	370	19	13
a1 — только закрепление	по-казахски	только (1)	21.2%	0.093	445	16	6
a2	по-казахски	да	40.0%	0.176	161	25	4
b0	англ., первая гипотеза	—	31.8%	0.092	465	17	18
b2	англ., первая гипотеза	да	36.5%	0.150	229	22	7
c2 — итог	**англ., короткое имя**	**да**	**44.7%**	**0.217**	**114**	34	**0**
c2s	англ., короткое имя, строгий порог	да	38.8%	0.153	260	14	7
e	c2 + поиск	да	36.5%	0.176	168	31	4

Таблица 3. Итог на настроечных сценах: 37.6 → 44.7% (a0 → c2), попарно 19 / 13, p = 0.38 — на 85 эпизодах не значимо. Главная потеря c2 — ложные остановки (34 из 47 неудач).

5.2. Проверка на свежих сценах dev3 (пылесос, 72 эпизода, 10 новых сцен)

вариант	kk	kk_ru	en
Qolda, итоговые настройки	**23.6%**	20.8%	19.4%
Qwen3-VL-4B, итоговые настройки	15.3%	15.3%	20.8%
переводчик NLLB → Qwen	16.7%	13.9%	—
без проверки объекта (Qolda / Qwen)	8.3% / 8.3%	—	—
Qolda, старые настройки (до недели)	25.0%	—	—
без языковой модели (как VLFM)	20.8%		
идеальный детектор	75.0%		

Таблица 4. На свежих сценах успех не вырос (Qolda kk 25.0 → 23.6%, p = 1.0): прирост на настроечных сценах был в пределах шума. Выросла эффективность: SPL 0.076 → 0.111, шагов 357 → 117. Сцены трудные: без языковой модели 20.8%.

шаг	успех Qolda kk	SPL	шагов
старые настройки: вопрос по-казахски, стоп 0.6 м, калибровка 10 сцен	25.0%	0.076	357
+ «последний метр» + калибровка 18 сцен (вопрос по-казахски)	20.8%	0.084	183
+ вопрос по-английски с коротким именем (итог)	23.6%	0.111	117

Таблица 5. Вклад изменений на свежих сценах dev3 (Qolda kk). Каждое меняет успех в пределах ±3 эпизодов, но делает робота быстрее.

Что подтвердилось на свежих сценах (гипотезы статьи):

- **H4 — проверка объекта нужна:** Qolda kk с проверкой 17 успехов против 6 без неё (13 / 2, p = 0.007).
- **H1 — разрыв «английский − казахский» у мультиязычной модели — из-за языка:** Qwen 11 раз не понял казахскую команду («төсек» → door); у Qolda ошибок понимания 0 на всех языках; у переводчика 18 непониманий.
- **H3 — направление в пользу Qolda:** kk 17 против 11 у Qwen, kk_ru 15 против 11 (не значимо).

5.3. Своя лёгкая проверка SigLIP 2 (без языковой модели)

кропы проверки (сохранённые из прогонов)	Qolda / Qwen: AUROC	SigLIP: AUROC
Qolda, вопрос по-английски, пылесос	0.791	**0.905**
Qolda, вопрос по-казахски, пылесос	0.801	**0.890**
Qolda, свежие сцены dev3	0.803	**0.937**
Qwen, стандартный агент	**0.943**	0.936
обученная сеть поверх SigLIP, кропы робота	—	0.834 (хуже необученной 0.881)

Таблица 6. AUROC — насколько хорошо отличает цель от чужого предмета (1 — идеально, 0.5 — наугад). SigLIP без обучения различает лучше Qolda.

вариант (пылесос, итоговые настройки)	dev3: проверка VLM	dev3: проверка SigLIP	dev4: проверка SigLIP
Qolda kk	23.6%	26.4%	20.8%
Qwen kk	15.3%	18.1%	26.4%
переводчик NLLB → Qwen kk	16.7%	9.7%	8.3%
Qwen en	20.8%	—	16.7%
без языковой модели	20.8%		27.8%
идеальный детектор	75.0%		68.1%

Таблица 7. На роботе большой офлайн-выигрыш превратился в +2 эпизода (dev3, правило требовало +5). На dev4: Qolda значимо лучше переводчика (11 / 2, p = 0.022); порядок Qolda / Qwen меняется от набора к набору (шум ±11 п.).

Почему офлайн-выигрыш не стал выигрышем на роботе («лотерея ложных кандидатов»). До настоящей цели робот встречает в среднем около двух похожих чужих предметов, и на каждом может ошибочно остановиться. Успех ≈ (дошёл бы) × (1 − доля ложных «да»)² × (доля верных «да»). Снижение ложных «да» с ~25% до ~16% даёт лишь ×1.25; чтобы выйти на 40% и выше у низкой камеры, ложных «да» должно быть ≤ 5%.

5.4. Этап 5: итоговая система на стандартном роботе (камера 0.88 м, 150 эпизодов)

Те же настройки, что итоговые для пылесоса (промпт v4, английский вопрос с коротким именем, «последний метр», проверка — сама языковая модель), калибровка — по вызовам на других сценах (dev2 + dev3, пересечение с этими эпизодами 0). Ничего не выбиралось.

вариант	успех	95% интервал	SPL	шагов (медиана)
Qolda, команда на казахском (итоговая система)	**44.0% (66/150)**	**36–52**	**0.232**	**181**
Qwen3-VL-4B, команда на английском (итоговая система)	**40.7%** (61/150)	33–49	0.220	131
Без языковой модели (как VLFM): готовое слово категории	**30.0%** (45/150)	23–38	0.177	69
Закрытый детектор, как в VLFM (RT-DETR)	**30.7%** (46/150)	24–38	0.171	201
Идеальный детектор (потолок навигации)	**71.3%** (107/150)	64–78	0.437	103

Таблица 8. Главный результат недели. До VLFM в статье (52.5% на val) около 8 п.; честное сравнение — только на val после заморозки плана (там другие сцены, а VLFM получает готовое английское слово категории, а не команду на казахском).

сравнение (одни и те же 150 эпизодов)	успехов	только первый / только второй	p (McNemar)
Qolda kk — без языковой модели	66 / 45	38 / 17	0.006 — **значимо**
Qolda kk — закрытый детектор (как VLFM)	66 / 46	36 / 16	0.008 — **значимо**
Qwen en — без языковой модели	61 / 45	30 / 14	0.023 — **значимо**
Qwen en — закрытый детектор	61 / 46	38 / 23	0.072
Qolda kk — Qwen en	66 / 61	28 / 23	0.576

Таблица 9. Попарные сравнения. Qolda kk значимо выше обеих базовых линий; от Qwen en не отличается.

исход эпизода	Qolda kk	Qwen en	без VLM	закрытый	идеальный
успех	66	61	45	46	107
ложная остановка (у чужого предмета)	15	29	72	15	3
видел цель, но не доехал / лимит шагов	27	15	13	3	13
цель ни разу не была в кадре	17	15	4	20	22
была в кадре, детектор не нашёл	6	4	2	58	1
проверка отвергла настоящую цель	13	6	0	0	0
остановился у цели, но дальше зоны успеха	6	20	14	8	4

Таблица 10. Чем кончались эпизоды (150 в каждом варианте). У Qolda ложных остановок 15 против 72 у базовой линии; теперь главные потери — поиск (не доехал, не увидел).

предмет	Qolda kk	Qwen en	без VLM	закрытый	идеальный
кровать	12/25	5/25	5/25	9/25	18/25
стул	19/25	16/25	10/25	17/25	23/25
растение	6/25	9/25	6/25	0/25	20/25
диван	13/25	11/25	6/25	0/25	15/25
унитаз	13/25	11/25	14/25	20/25	18/25
телевизор	3/25	9/25	4/25	0/25	13/25

Таблица 11. Успехи по предметам (25 эпизодов на предмет). Телевизоры трудны всем, кроме идеального детектора.

вариант (93 общих эпизода)	стандартный агент, 0.88 м	пылесос, 0.15 м
идеальный детектор	87.1%	78.5%
без языковой модели	37.6%	38.7%
Qolda kk	52.7%	18.3% (ранняя версия системы)
Qwen en	49.5%	33.3% (ранняя версия системы)

Таблица 12. Высота камеры. На одних и тех же эпизодах высокая камера сильно помогает методу с проверкой объекта. Ориентир, не чистый опыт: на пылесосе здесь — ранняя версия системы.

Честно о вкладе недели на стандартном роботе: Qwen en до этой недели (старые настройки, без калибровки) давал 43.3% на тех же 150 эпизодах, сейчас 40.7% (21 / 25, p = 0.66). Высокие цифры стандартного робота — заслуга всей системы и высокой камеры; изменения недели здесь дали меньше ложных остановок (37 → 29) и чуть выше SPL (0.201 → 0.220). Qolda на стандартном роботе прогнана впервые.

6. Выводы

Что получилось

- Итоговая система с казахскими командами на стандартном роботе — 44.0%, значимо выше базовых линий (30.0 и 30.7%); Qolda на казахском наравне с Qwen на английском.
- Языковые выводы (H1, H4, «родная модель против перевода») устойчивы на трёх наборах сцен.
- Узкое место точно найдено и измерено: точность решения «стоп» у низкой камеры и «лотерея ложных кандидатов».
- Робот стал эффективнее: в 2–3 раза меньше шагов, выше SPL.
- Методика: все решения — по правилам, записанным до прогонов; проверка на свежих сценах поймала ложное улучшение; тест не тронут.

Что не получилось

- Успех пылесоса на свежих сценах не вырос (пять попыток; лучшие дали +2–3 эпизода из 72).
- Улучшение 37.6 → 44.7% на настроечных сценах не перенеслось на новые.
- Обученная проверка оказалась хуже необученной (робот видит предметы иначе, чем генератор данных).
- Видеодрайвер сбрасывался под нагрузкой (8 раз за две недели), компьютер дважды выключался сам: время терялось, данные — нет.

Вопросы к руководителю

- Главная таблица статьи — стандартный робот (сравним с литературой), пылесос — вторая таблица «трудный случай» с разбором высоты камеры? Для чистого сравнения высот — итоговая система на пылесосе на тех же 93 эпизодах (~5–7 ч).
- Заморозить план анализа и запускать тест (val: 547 + 297 эпизодов)? Нужны 60 тестовых команд от носителей.
- Проверка у низкой камеры: принять как есть и описать, или дообучить проверку на кропах самого робота, или вернуться к дообучению Qolda?

7. Видео

Видео пишутся для 5% эпизодов — одних и тех же во всех вариантах, выбор заранее по номеру эпизода. Из 10 таких эпизодов этапа 5 Qolda дошла до предмета в 5 — они и взяты (выбраны специально, это иллюстрация, а не статистика). Каждый эпизод — во всех пяти вариантах: `reports/etap5_2026-10-24/video/<вариант>/`, в имени файла — номер, предмет и исход. В кадре: команда, гипотезы модели, решение проверки; слева вид камеры, в центре карта (зелёное — настоящая цель), справа карта ценности.

№	предмет	команда (kk / en)	Qolda kk	Qwen en	без VLM	закрытый	идеальный
1	растение	«Осы үйде өсімдік бар ма? Болса, соған апаршы» «Is there a plant in this house? If there is, take me to it.»	успех	ложная остановка	лимит шагов	не нашёл	успех
2	кровать	«Төсек қайда? Шаршап тұрмын» «Where's the bed? I'm tired.»	успех	остановился далеко	остановился далеко	успех	успех
3	растение	«Осы үйде өсімдік бар ма? Болса, соған апаршы» «Is there a plant in this house? If there is, take me to it.»	успех	успех	лимит шагов	лимит шагов	успех
4	диван	«Менің отырғым келеді, диван қайда?» «I want to sit down. Where's the couch?»	успех	успех	успех	лимит шагов	успех
5	стул	«Орындық жетіспей тұр, тауып берші» «We're missing a chair. Can you find one for me?»	успех	успех	успех	успех	успех

Таблица 13. Эпизоды с видео и чем они кончились в каждом варианте. В эпизоде 1 Qolda дошла, а Qwen остановился у чужого предмета; в эпизоде 2 Qwen и базовая линия остановились слишком далеко.



Кадр 1. Qolda kk, растение, «Осы үйде өсімдік бар ма? Болса, соған апаршы»: последний кадр — робот остановился у предмета (видео 1_qolda_kk/01_…).



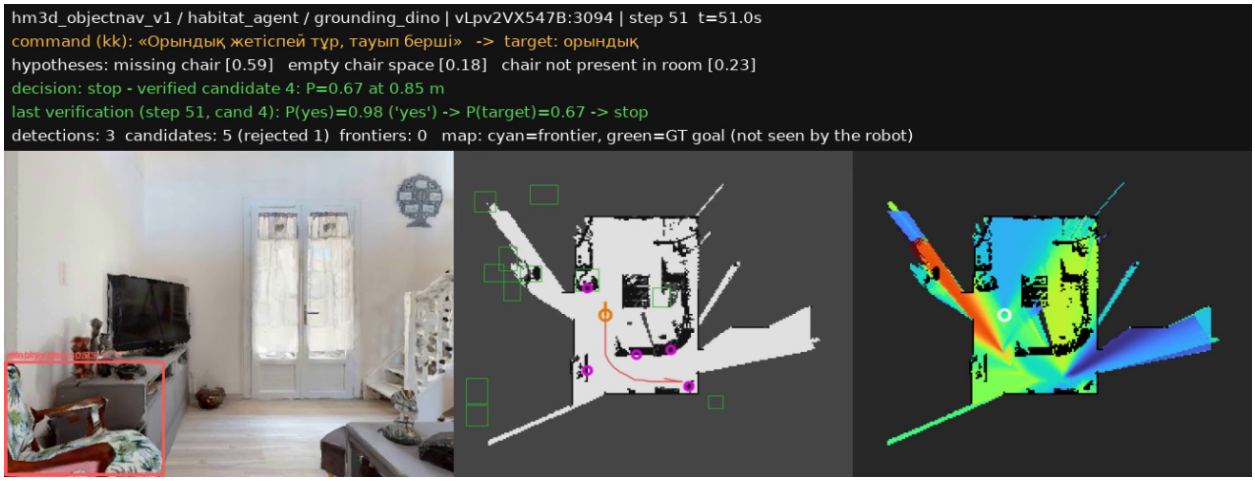
Кадр 2. Qolda kk, кровать, «Төсек қайда? Шаршап тұрмын»: последний кадр — робот остановился у предмета (видео 1_qolda_kk/02_…).



Кадр 3. Qolda kk, растение, «Осы үйде өсімдік бар ма? Болса, соған апаршы»: последний кадр — робот остановился у предмета (видео 1_qolda_kk/03_…).



Кадр 4. Qolda kk, диван, «Менің отырғым келеді, диван қайда?»: последний кадр — робот остановился у предмета (видео 1_qolda_kk/04_…).



Кадр 5. Qolda kk, стул, «Орындық жетіспей тұр, тауып берші»: последний кадр — робот остановился у предмета (видео 1_qolda_kk/05_…).