Навигация робота-пылесоса по командам на казахском языке

Отчёт о состоянии проекта kznav: идея, архитектура, результаты, план

Алибек Жайлеубай · 10 октября 2026

Коротко

- **Что делаем.** Робот в незнакомой квартире ищет предмет по голосовой/текстовой команде на казахском (или смешанном казахско-русском, или английском) и останавливается рядом с ним. Обучения под эту задачу нет: система собрана из готовых моделей «язык + зрение» и классических модулей навигации (zero-shot).
- **Зачем.** Почти все такие системы проверяют только на английском. Мы хотим понять, **где именно** ломается цепочка «команда → понимание → поиск глазами → остановка» для казахского, особенно для культурных предметов (қазан, сандық, көрпе…), и помогает ли модель, обученная на казахском (Qolda).
- **Что уже есть.** Рабочий стенд в симуляторе Habitat на реальных сканах квартир (HM3D), две модели (Qolda, Qwen3-VL), колёсный робот с камерой на 15 см и стандартный агент Habitat, 422 автотеста, журнал из 63 решений.
- **Главные цифры (dev, не тест).** Перевод на английский теряет культурные предметы: 1/15 против 11/15 у Qolda ($p = 0.002$). Проверка VLM перед остановкой нужна: на стандартном агенте метод 43.3% против 30.0% у базовой линии без проверки ($p \approx 0.004$). До опубликованного уровня VLFM (52.5%) осталось ~9 пунктов.
- **Что дальше.** Калибровка проверки (≈2–3 дня работы GPU), заморозка плана анализа, главная таблица на тестовых эпизодах (≈10–12 дней GPU), культурная часть, статья. До подачи — ориентировочно 2.5–3 месяца.

1. Идея: что изучаем и зачем

Задача. Это задача ObjectNav («найди объект»): робот появляется в незнакомой квартире, получает команду, например «Төсекті тауып берші» (найди кровать), сам исследует квартиру и должен остановиться рядом с предметом — не дальше примерно 1 м и так, чтобы предмет было видно. Карты квартиры у робота нет, он строит её сам по камере.

Почему казахский. Казахский — язык с малым количеством данных. Люди в Казахстане часто говорят смешанно (казахский + русский). Есть предметы, которых нет в англоязычных наборах данных (қазан, сандық, көрпе, дастархан, домбыра). Если просто переводить команду на английский, такие слова теряются.

Почему робот-пылесос. Это самый массовый домашний робот. Его камера стоит низко (у нас 15 см), поэтому мир он видит снизу: крупные планы ножек мебели, стены. Такая точка обзора почти не изучена, а мы потом хотим проверить систему на настоящем роботе.

Как сравниваем. Две «языковые» модели: **Qolda-4B** (обучена в т.ч. на казахском) и **Qwen3-VL-4B** (общая многоязычная). Три языка команды: казахский (kk), смешанный (kk-ru), английский (en). Плюс базовые линии: классический подход VLFM (детектор ищет английское название категории, без VLM) и «сначала перевести» (машинный перевод NLLB-200, потом английская система).

2. Гипотезы

	Гипотеза простыми словами	Как проверяем
H1	Главные ошибки — на стыке языка и зрения: модель понимает слово, но неправильно описывает предмет детектору или неправильно проверяет найденное.	Каждую неудачу относим к одному этапу (не понял / не увидел / не обнаружил / ложная остановка / проверка отвергла …) и сравниваем kk и en.
H2	Для культурных предметов разрыв больше, а подход «сначала перевести» его увеличивает.	Пары «культурный предмет ↔ похожий обычный» (қазан ↔ кастрюля и т.д.): фото-набор и 3D-модели в квартирах.
H3	Модель с «родным» казахским (Qolda) сокращает разрыв kk/en по сравнению с общей моделью (Qwen3-VL).	Одни и те же эпизоды, команды и промпты; меняется только модель.
H4	Перед остановкой нужна проверка моделью (VLM смотрит на кандидата), а её уверенность нужно калибровать.	Метод с проверкой против того же без проверки; ошибка калибровки (ECE).

3. Архитектура системы

Система модульная, как у VLFM (ICRA 2024) и ApexNav (2025): отдельные готовые модели для языка, детекции, сегментации и «чутья» направления, а навигация — классическая (карта + планировщик). Ниже — полная схема метода.

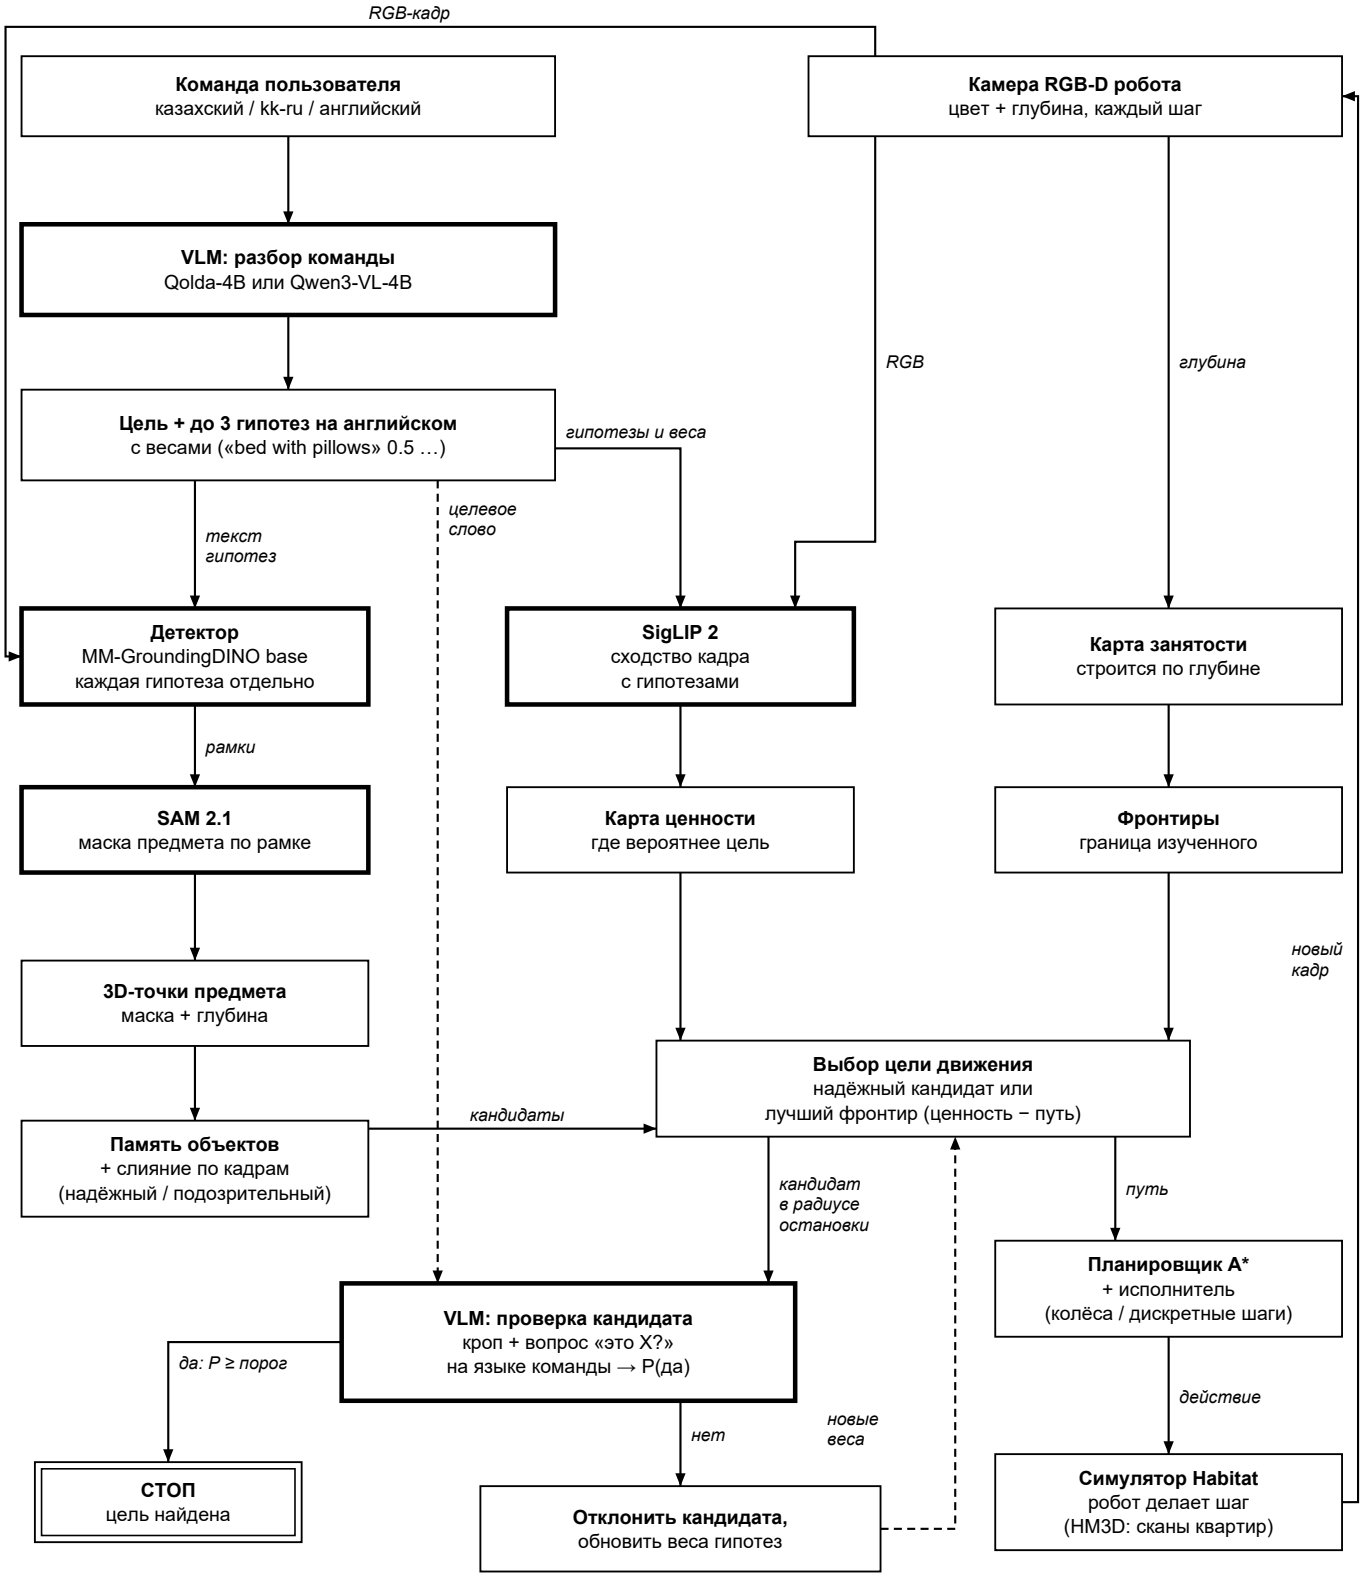


Рис. 1. Схема метода. Толстая рамка — нейросетевые модели, тонкая — алгоритмы без обучения, пунктир — служебные связи и обратная связь. Цикл «камера → решение → шаг → новый кадр» повторяется каждый шаг (колёсный робот: шаг 0.5 с, до 800 шагов; стандартный агент: до 500 действий). Базовая линия VLFM-style отличается тем, что VLM нет: детектор ищет английское название категории («bed»), остановка без проверки.

Как это работает, по шагам

- **1. Разбор команды (один раз в начале).** VLM читает команду на любом из трёх языков и возвращает JSON: целевое слово на языке команды (например «төсек»), до трёх английских описаний предмета для детектора с весами («bed in a bedroom» 0.5, «bed with pillows» 0.3 …) и вероятные комнаты.
- **2. Каждый шаг — восприятие.** Камера даёт цветной кадр и глубину. Детектор ищет каждую гипотезу отдельно (D-058). Найденную рамку SAM 2 превращает в точную маску предмета; по маске и глубине получаем 3D-точки предмета. Параллельно SigLIP 2 оценивает, насколько весь кадр похож на гипотезы — это пишется в «карту ценности» (куда вероятнее ехать).
- **3. Память и слияние.** Находки в одном месте объединяются в «кандидата». Уверенность кандидата копится по кадрам и падает, если кандидат в поле зрения, а детектор его больше не видит (идея ApexNav). Ехать можно только к «надёжным» кандидатам; это отсекает одиночные галлюцинации детектора.
- **4. Куда ехать.** По глубине строится карта занятости, на ней — фронтиры (граница изученного). Если есть надёжный кандидат — едем к нему; иначе выбираем фронтир с лучшим «ценность минус длина пути» (как VLFM). Путь строит A*, исполнитель превращает его в движение (колёса или дискретные шаги).
- **5. Проверка и остановка.** Когда кандидат рядом, VLM получает вырезанный кусок кадра и вопрос на языке команды («Бұл төсек пе?»). Вероятность «да» берётся из лог-вероятностей ответа и калибруется. «Да» — стоп; «нет» — кандидат отвергается, веса гипотез пересчитываются (байесовски), поиск продолжается.

Модели и их роли

Модель	Что это	Роль у нас	Вход → выход	Когда и сколько стоит
Qolda-4B (ISSAI, bf16)	VLM, обучена в т.ч. на казахском	Разбор команды; проверка кандидата	текст → JSON (цель, 3 гипотезы, веса, комнаты); кроп + вопрос → P(да)	разбор 1 раз (~4.7 с); проверка ~1–2 с
Qwen3-VL-4B-Instruct (bf16)	Общая многоязычная VLM	То же — для сравнения (H3)	то же	разбор ~3.8 с; проверка ~1–3 с
MM-GroundingDINO base (Swin-B)	Открытый детектор: ищет предмет по тексту	Найти рамки гипотез в кадре	кадр + фраза → рамки и уверенность	каждый шаг, по проходу на гипотезу, ~0.1 с
SAM 2.1 Hiera-tiny	Сегментация по подсказке-рамке	Точная маска предмета → точное положение	кадр + рамка → маска	только при находках, ~55 мс
SigLIP 2 base	Сопоставление картинки и текста	Карта ценности: какое направление перспективнее	кадр + гипотезы → число сходства	каждый шаг
NLLB-200 (600M)	Машинный переводчик	Только базовые линии «сначала перевести»	казахский текст → английский	1 раз на команду, CPU
RT-DETR R101 (COCO)	Закрытый детектор, класс YOLO	Справочная строка «как у VLFM» (YOLOv7, порог 0.8)	кадр → рамки 80 классов COCO	только в справочной строке
Идеальный детектор	Разметка симулятора	Потолок навигации: что было бы при идеальном зрении	семантика → маски цели	для сравнения

Без обучения (алгоритмы): карта занятости по глубине (log-odds), поиск фронтиров, память объектов со слиянием, A* на карте, исполнитель (колёсный робот — регулятор pure pursuit и кинематическая модель на собственной навигационной сетке; стандартный агент — шаги 0.25 м и повороты 30°, столкновения отмечаются на карте, D-063).

Роботы, симулятор, данные

	Колёсный робот-пылесос (главная таблица)	Стандартный агент Habitat (сравнение с литературой)
Камера	RGB-D 640×480, обзор 69°, высота 0.15 м, наклон 20° вверх	RGB-D 640×480, обзор 79°, высота 0.88 м
Движение	Радиус 0.17 м, скорость/ускорение ограничены, движение по своей навигационной сетке (подъём 1 см)	Дискретно: вперёд 0.25 м, поворот 30°
Лимит эпизода	800 решений по 0.5 с (выбрано на dev, D-005)	500 действий (стандарт Habitat)
Успех	Остановился ≤ 0.1 м от точки обзора цели (≈1 м от предмета, предмет виден); точки обзора пересчитаны для низкой камеры	То же, точки обзора из набора данных

- **Симулятор:** Habitat-Sim. **Квартиры:** HM3D v0.1 — 3D-сканы реальных квартир. **Эпизоды:** ObjectNav HM3D v1, 6 категорий: кровать, стул, растение, диван, унитаз, телевизор. val — 2000 эпизодов в 20 квартирах (отсюда тест), train — 80 квартир (отсюда dev для настройки).

- **Железо:** одна видеокарта RTX 5070 12 ГБ; все модели локально в bf16, весь стек влезает (пик 11.8 из 12.2 ГБ). Облака нет.
- **Правило честности:** всё настраивается только на dev (тренировочные квартиры) по правилу, записанному **до** прогона. Тестовые эпизоды пока не трогали ни разу.

4. Что сделано

Блок	Что сделано
Стенд kznav	Конфиги (Hydra), сменные модели и роботы, запись каждого вызова модели и каждого шага, воспроизводимость (60/60 эпизодов совпали при повторе), 422 автотеста, журнал решений D-001…D-063.
Язык	Промпты разбора и проверки (выбраны на dev), разбор с весами гипотез, проверка по лог-вероятностям, калибровка (Платт/изотоническая), байесовское обновление весов гипотез.
Отладка	Своя комната с 4 предметами YCB: проверка всей цепочки, абляции (одна гипотеза, перевод NLLB), сравнение Qolda и Qwen, английский контроль.
HM3D	Скачаны и проверены сканы и эпизоды; цели сопоставлены точно; отобраны эпизоды, доступные пылесосу; выборки dev/test; анализ мощности; точки обзора для низкой камеры.
Настройка на dev	Наклон камеры (20°), лимит шагов (800), детектор и его порог, разрешение входа, маски, слияние, движение стандартного агента — каждое по заранее записанному правилу.
Найденные ошибки	D-056 точки обзора высоких целей; D-058 гипотезы одной строкой делали детектор слепым; D-061 спуск по лестнице считался «падением»; D-063 столкновения не передавались политике.
Команды	Банк естественных команд: 12 dev-команд от 2 авторов на kk / kk-ru / en; 60 тестовых — впереди.
Культурная часть	Инструменты готовы (12 пар «культурный ↔ обычный», оценка на фото, инструкция для сбора); фото и 3D-модели ещё не собраны.

5. Результаты

Важно: всё ниже — пилот, отладочная комната или dev (тренировочные квартиры HM3D). Это «настройка прибора», а не итоговые цифры статьи. Маленькие выборки (20–30) показывают тенденции, а не доказательства. p — точный тест Макнемара / знаковый тест на парах.

5.1. Пилот: понимает ли модель казахскую команду (30 команд: 15 культурных, 15 обычных)

Qolda, разбор 30 команд	Все	Культурные	Обычные
Валидный JSON с 1-й попытки	1.00	1.00	1.00
Цель в словарной форме	0.73	0.73	0.73
Гипотеза называет предмет (главное слово)	0.83	0.73	0.93
Задержка, медиана	4.8 с	4.9 с	4.6 с

Ошибки Qolda: кебеже → kitchen knife, тұскиіз → curtain, саба → umbrella, самауырын → sieve, термос → thermostat (D-029). Для сравнения, исходный пилот (до стенда, другой промпт): цель совпала в 0.80, задержка 10.6 с; проверка 0.84, ECE 0.16.

Что получает детектор	Культурные	Обычные	Все	Валидный JSON
Qolda, все гипотезы (метод)	**11/15**	14/15	25/30	30/30
Qolda, одна гипотеза	10/15	13/15	23/30	30/30
NLLB переводит слово (слово дано)	1/15	9/15	10/30	—
NLLB переводит команду → Qolda по-английски	1/15	11/15	12/30	24/30

Перевод против метода: p = 0.0001 по всем, p = 0.002 на культурных. NLLB: қазан → «October», сандық → «numerical», домбыра → «drums», көрпе → «not see», дастархан → «the desktop», бесік → «the girl». Самый сильный результат по H2 на сегодня (D-038/D-039).

Qolda против Qwen3-VL-4B (пилот)	Qolda	Qwen3-VL-4B
Запрос называет предмет: культурные / обычные	**11/15** / 14/15	3/15 / 11/15
Цель в словарной форме	22/30	24/30
Проверка 32 кропов: точность (культурные / обычные)	0.81 (0.69 / 0.94)	0.69 (0.56 / 0.81)
Ошибка калибровки ECE	**0.14**	0.32
Средняя уверенность в ошибочных ответах	0.65	0.97
Задержка разбора, медиана	4.7 с	3.8 с

Культурные слова: p = 0.02 в пользу Qolda. Qwen придумывает по контексту: бесік → window sill, кесе → bridge, шапан → hat, ошақ → window, домбыра → drum, дастархан → cushion (D-040). Число «тайлов» картинки (1 / 4 / 12) на точность проверки не влияет (0.875 / 0.81 / 0.81), выбрано 4 (D-029).

5.2. Отладочная комната (1 сцена, 4 предмета YCB, 20 эпизодов на вариант, точность ±20 п.)

Вариант (колёсный робот)	Успех	Ложные остановки
Идеальный детектор (потолок)	15/20 (75%)	0
GroundingDINO, без VLM (ближайший фронтир / карта ценности / порог 0.6)	1/20 / 1/20 / 2/20	19 / 19 / 14
Qolda kk без проверки	1/20	15
Qolda kk + проверка	**6/20**	**1**
Qolda kk-ru + проверка	4/20	0
Qolda en + проверка / без проверки	6/20 / 1/20	0 / 19
Qwen3-VL: kk / kk-ru / en (+ проверка)	2/20 / 6/20 / 9/20	—
Абляции: одна гипотеза / NLLB-слово + проверка / NLLB-слово без проверки / NLLB-команда	5/20 / 3/20 / 1/20 / 1/20	0 / 0 / 18 / 1

Проверка в цикле отвергла 441 из 443 чужих предметов и подтвердила 15 из 19 настоящих целей. Qolda против Qwen в навигации: kk 6 против 2, kk-ru 4 против 6, en 6 против 9 — ни одна разница не значима на 20 эпизодах (D-035, D-037, D-038/39, D-040).

5.3. HM3D: данные, выборки, мощность

- Сопоставление целей набора с разметкой сцен — точное (расхождение позиции $5 \cdot 10^{-6}$ м). Наша реализация GroundingDINO совпала с оригинальной на 89 из 89 рамок (D-009).
- Без наклона камеры пылесосу было доступно лишь 1039 из 2000 эпизодов, телевизоров — 12 из 281 (с 15 см их не видно) — отсюда исследование наклона.
- Дымовой прогон на val_mini (идеальный детектор, не результат): стандартный агент 60% (30 эп.), физический пылесос 55% (11 эп.) — все провалы механические; базовая линия VLFM-style на нём же ложно остановилась в 11 из 11 эпизодов (D-052, D-054).
- Пылесосу доступно **1225 из 2000** эпизодов val (при наклоне 20°): 629 — цель на другом этаже или за ступенькой, 124 — старт вне его навигационной сетки, 22 — цель не видна. По категориям: кровать 229, стул 304, растение 47, диван 239, унитаз 224, телевизор 182.
- Выборки: **тест основной 547** (по 100 на категорию, растений все 47), **тест вторичный 297** (вложен), **dev 150** (по 25, 10 тренировочных квартир). Тест и dev не пересекаются — разные квартиры.
- Мощность ($\alpha = 0.05/5$, 20 сцен): на 547 эпизодах эффект 10 п. виден с вероятностью 0.81 ($\psi = 0.3$) / 0.69 ($\psi = 0.4$), эффект 15 п. — > 0.99 / 0.98; на 297 эпизодах — 0.51 / 0.39 и 0.93 / 0.82.
- Физический робот против кинематического (val_mini, идеальный детектор): 6/11 (4 застревания, 1 падение — сканы физически неточны) против 10/11 → главная таблица в кинематике, физика — в исследовании устойчивости (D-053).

5.4. Настройка колёсного робота на dev

Наклон камеры (идеальный детектор, 76 эп.)	0°	10°	20°	30°
Успех	65.8%	76.3%	**77.6%**	36.8%
Телевизоры	0/10	3/10	5/10	1/10
Цели видны хотя бы из одной точки (360 эп.)	89.6%	91.8%	94.5%	95.9%

Лимит шагов	100	200	300	400	500	600	700	800	900	1000
Успех (идеальный детектор, 150 эп.)	32%	59%	69%	72%	78%	79%	81%	**81.3%**	82%	82%

Выбрано наименьшее значение с ≥ 99% от успеха при 1000 шагах (D-004, D-005). При 1000 шагах: 123 успеха из 150, медиана успешного эпизода 120 шагов, максимум 877.

Старый детектор GroundingDINO-tiny, базовая линия	0.35	0.50	0.65	0.75	0.85	Идеальный
Успех	2.7%	10.7%	**14.0%**	10.7%	5.3%	75.3%
Ложные остановки	94%	83%	41%	17%	3%	0.7%

С камеры на 15 см детектор «видит» цель там, где её нет: при пороге по умолчанию 94% остановок ложные (D-054). Позже: вход без растяжения 640×480 → детекция в 2.2 раза быстрее (219 против 479 мс на 3 гипотезы), успех 16.0 / 12.0 / 12.7% при порогах 0.50 / 0.65 / 0.75 (D-059).

5.5. Почему метод сначала «не видел» объекты (D-058)

Первый пробный прогон Qolda: **0 находок за 1925 шагов**, хотя базовая линия на тех же эпизодах видела кровать 4–7 раз за эпизод. Причина: гипотезы шли детектору одной строкой «q1 . q2 . q3 .», и он почти переставал отличать кадр с целью от кадра без неё. Проверка на 574 кадрах камеры робота (424 с целью, 150 без):

Что подаём детектору (порог 0.65)	Цель есть: нашёл	Цели нет: ложно	AUROC
Название категории («bed»)	15.6%	2.7%	0.62
Гипотезы Qolda одной строкой	1.7%	≈0%	0.55
Гипотезы Qwen одной строкой	0%	0%	0.54
Гипотезы Qolda по одной (исправление)	**35.5%**	19.9%	0.61
Гипотезы Qwen по одной	**31.2%**	16.8%	0.60

После исправления пробные 8 эпизодов (проверка не откалибрована): Qolda 0/8 (2 ложные остановки, 3 «у цели, но далеко», 2 лимит, 1 не нашёл), Qwen 0/8 (5 ложных, 2 далеко, 1 застрял); проверка Qolda: 0.95 настоящей кровати и ≤ 0.03 чужим предметам, Qwen — только 0 или 1. Примеры H1: Qwen понял «төсек» (кровать) как «дверь» (обе команды про кровать → open door, wooden door…), Qolda поняла «Орындық жетіспей тұр» буквально — «missing chair». Время тогда: ~0.69 с на шаг, ~5 мин на эпизод (до ускорения D-059).

5.6. Новая система восприятия (D-060) — по образцу лучших работ

Детектор (574 кадра робота)	Метод: Qolda	Метод: Qwen	Главная метрика	Название категории	мс/запрос
MM-GroundingDINO base (выбран)	0.372	0.297	**0.334**	0.422	98
GroundingDINO tiny (был)	0.277	0.242	0.259	0.311	89
LLMDet base	0.285	0.232	0.259	0.290	99
MM-GroundingDINO tiny	0.260	0.236	0.248	0.248	77
GroundingDINO base	0.263	0.224	0.244	0.337	101
LLMDet tiny	0.233	0.210	0.222	0.233	79
RT-DETR, закрытый COCO (класс YOLO)	—	—	—	0.259	46/кадр

Доля кадров с целью, где детектор нашёл рамку именно на цели, при 10% ложных срабатываний. Закрытый детектор с низкой камеры хуже открытого: при пороге VLFM 0.8 он почти не ошибается (0.2%), но находит цель лишь в 6.4% кадров.

Маски (378 кадров с целью)	Доля маски на предмете	Покрыто предмета	IoU
Рамка как маска (было)	0.47	1.00	—
SAM 2.1-tiny	**0.86**	0.93	0.81

Пустых масок нет, ~55 мс на кадр; хуже всего стулья (IoU 0.70).

Колёсный робот, базовая линия, dev 150	Успех	SPL	Ложные ост.	Лимит
Было: GroundingDINO-tiny 0.65, рамки (D-054)	14.0%	0.055	41%	31%
Новый стек, порог детектора 0.35 / **0.50** / 0.65 (слияние 0.45)	32.0 / **32.0** / 28.0%	0.133 / 0.142 / 0.091	57 / 43 / 21%	6 / 13 / 35%
Порог 0.50, слияние 0.30 / **0.45** / 0.60	30.0 / **32.0** / 26.7%	0.146 / 0.142 / 0.109	50 / 43 / 26%	10 / 13 / 33%
Идеальный детектор (потолок)	75.3%	0.397	0.7%	17%

Базовая линия колёсного робота выросла больше чем вдвое: 14% → 32%; «остановок мимо цели» вдвое меньше (8.7% → 4.7%).

5.7. Стандартный агент и сравнение с мировым уровнем

Лучшие zero-shot методы, HM3D v1 val	VLFM	SG-Nav	OpenFMNav	TriHelper	ApexNav
Успех / SPL	52.5 / 30.4	54.0 / 24.9	54.9 / 24.4	56.5 / 25.3	59.6 / 33.0

Новые работы 2025–2026 заявляют 65–81%, но на HM3D v2, с многоэтажностью или крупными закрытыми моделями — напрямую несравнимо.

- **Старый стек** на стандартном агенте: базовая линия 6.0% (87% ложных остановок), идеальный детектор 58.7%.
- **D-061:** спуск по лестнице считался «падением» — оборвано 23 из 150 эпизодов идеального детектора. Исправлено.
- **Новый стек D-060:** базовая линия 34.0%, идеальный детектор 65.3%, метод Qwen-en 36.0% (ложные остановки 17% против 36%, но 39% эпизодов упирались в лимит шагов).
- **Закрытый детектор как у VLFM** (RT-DETR 0.8 + маски): 28.7%, со слиянием 32.7% — разрыв с VLFM не только в детекторе (D-062).

- **D-063:** разбор каждого действия показал, что треть шагов агент упирался в препятствия (идеальный детектор: вперёд 29%, повороты 36%, без движения 36%) — столкновения не передавались политике. Исправлено и настроено на dev:

Движение стандартного агента (идеальный детектор, 150)	**Успех**	**SPL**	**Лимит шагов**
Как было	65.3%	0.405	23%
Отмечать столкновения, ориентир 0.25 м, допуск 15°	72.0%	0.428	9%
То же, ориентир 0.75 м, допуск 15°	38.7%	0.272	58%
То же, ориентир 0.75 м, допуск 25°	49.3%	0.316	45%
Отмечать столкновения, 0.25 м, 25° (выбрано)	**73.3%**	**0.433**	**6%**

Стандартный агент после исправлений, dev 150	**Успех [95% ДИ]**	**SPL**	**Ложные ост.**	**Лимит**	**Не нашёл**
Метод: Qwen3-VL-4B, en (проверка не откалибрована)	**43.3%** [35, 51]	0.201	37	25	14
Базовая линия, наш стек (без VLM)	30.0% [23, 37]	0.177	72	11	8
Закрытый детектор как VLFM / + слияние	30.7% / 34.0%	0.171 / 0.193	15 / 13	33 / 34	48 / 48
Идеальный детектор (потолок)	73.3% [66, 80]	0.433	3	9	24

Метод против базовой линии на тех же эпизодах: 32 выиграл только метод, 12 — только базовая линия, p ≈ 0.004. Неудачи метода: ложная остановка 37, увидел, но не дошёл 20, цель не попала в кадр 11, остановился далеко 9, проверка отвергла цель 6, не обнаружил 2. По категориям (метод / потолок, из 25): стул 18/23, унитаз 14/25, диван 11/16, кровать 10/18, телевизор 7/11, растение 5/17. Базовая линия после исправления движения чуть просела (34 → 30%): робот быстрее доезжает до ложных кандидатов — чем лучше движение, тем нужнее проверка.

5.8. Итог по гипотезам на сегодня

	Что уже видно	**Чего не хватает**
H1	Ошибки возникают именно при переходе от слова к описанию для детектора (кебеже → kitchen knife; Qwen: төсек → дверь; «Орындық жетіспей тұр» → missing chair).	Разбор неудач по этапам на тестовых эпизодах, kk против en.
H2	**Сильнее всего:** перевод теряет культурные предметы — 1/15 против 11/15 у Qolda (p = 0.002), на обычных разница меньше (9–11/15 против 14/15).	Культурные предметы в навигации (фото и 3D-модели).
H3	Пилот: Qolda лучше на культурных словах (11/15 против 3/15, p = 0.02) и лучше откалибрована (ECE 0.14 против 0.32). Отладка: kk 6 против 2 — тенденция.	Главная таблица на тестовых эпизодах с калибровкой.
H4	Проверка нужна: отладка 6/20 против 1/20; стандартный агент 43.3% против 30.0% (p ≈ 0.004); у Qwen уверенность 0/1, ECE 0.32.	Калибровка и её эффект на ложные остановки.

6. Плюсы и минусы работы

Плюсы	**Минусы и риски**
• Новая постановка: казахский и смешанный язык, культурные предметы, низкая камера пылесоса — почти не изучено. • Строгая методика: настройка только на dev по правилам, записанным до прогонов; тест не тронут; статистика по квартирам; поправка Холма; заранее посчитанная мощность. • Найдены и исправлены реальные ошибки, каждая с измеренным эффектом: базовая линия колёсного робота 14% → 32%, стандартного агента 6% → 34%, потолок навигации 65% → 73%. • Метод значимо лучше базовой линии без проверки (p ≈ 0.004). • Сильный языковой результат: перевод теряет культурные слова (p = 0.002). • Всё воспроизводимо: 422 теста, журнал из 63 решений, запись каждого вызова модели. • Всё работает локально на одной видеокарте, без платных API.	• Главных (тестовых) результатов ещё нет: все цифры — dev, пилот и отладка. • Метод пока ниже VLFM: 43.3% против 52.5% (наш dev против их val — сравнение приблизительное). • Проверка ещё не откалибрована; 25% неудач метода — ложные остановки. • У колёсного робота абсолютный успех низкий (32% у базовой линии при потолке 75%) — низкая камера трудна для любого детектора. • Только две модели по 4B; рецензент может попросить большую или закрытую модель. • Только симуляция; реальный робот — позже. • В HM3D нет культурных предметов: для H2 нужны свои фото и 3D-модели — данных пока нет. • 60 тестовых команд от носителей ещё не написаны. • Вычисления долгие: эпизод с VLM ~2–5 мин, главная таблица ~10–12 дней одной видеокарты.

7. План дальше

#	Что	Зачем	Время
1	Калибровка проверки: Qolda и Qwen × kk / kk-ru / en × 150 dev-эпизодов	Убрать ложные остановки (25% неудач метода); проверить H4	≈2–3 дня GPU
2	Абляции для статьи: без слияния, без масок	Показать вклад каждого узла	≈5 ч GPU
3	Метод на стандартном агенте с калибровкой; таблица (a) на случайной выборке всего val	Честное сравнение с VLFM и другими работами	≈2 дня GPU
4	60 тестовых команд от носителей + рецензия второго человека	Без них нельзя запускать главную таблицу	1–2 недели (параллельно)
5	Заморозить план анализа (метка в git)	После этого цифры теста нельзя «подгонять»	1 день
6	Главная таблица: колёсный робот, 547 + 297 тестовых эпизодов, все варианты	Ответы на H1, H3, H4	≈10–12 дней GPU
7	Исследование устойчивости: шумы датчиков, ошибки привода, физика	Шаг к реальному роботу	≈4 дня GPU
8	Культурная часть: ~480 фото (12 пар) и 48–72 3D-модели в квартирах	Проверка H2	сбор 2–4 недели; код 4–6 дней; прогоны ≈5 дней
9	Статья: текст, таблицы, графики, правки	Подача в журнал	4–6 недель

Вычисления идут в одной очереди на одной видеокарте (≈25 дней счёта всего); их можно гонять ночами, прогоны продолжаются с места остановки. Реалистично до подачи — 2.5–3 месяца.

8. Словарик

Термин	Что значит
ObjectNav	Задача «найди объект» в незнакомом помещении по названию.
Zero-shot	Без обучения под эту задачу: система собрана из готовых моделей.
VLM	Модель «зрение + язык»: понимает текст и картинки (у нас Qolda, Qwen3-VL).
Детектор	Находит на кадре рамку вокруг предмета; «открытый» — по любому тексту, «закрытый» — только заранее известные классы.
Гипотезы	Английские описания предмета от VLM для детектора, с весами.
Карта ценности	Карта «где вероятнее цель» по похожести кадров на гипотезы (SigLIP 2).
Фронтир	Граница между изученной и неизученной частью квартиры — туда едут исследовать.
Слияние по кадрам	Уверенность в кандидате копится по многим кадрам и падает, если его перестали видеть.
Проверка / верификация	Перед остановкой VLM смотрит на кандидата и отвечает «да / нет».
Калибровка	Поправка, чтобы «уверенность 90%» действительно означала 90% правильных ответов.
SR / SPL	Доля успешных эпизодов / успех с учётом длины пути (1 — кратчайший путь).
Ложная остановка	Остановился у чужого предмета.
Идеальный детектор	Детектор с разметкой симулятора — показывает потолок навигации.
dev / test	dev — тренировочные квартиры для настройки; test — отдельные квартиры только для итоговых цифр.
AUROC, ECE	AUROC — насколько хорошо модель отличает «есть / нет» (0.5 — как монетка); ECE — ошибка калибровки.
p	Вероятность получить такую разницу случайно; $p < 0.05$ — разница считается значимой.